

Data Scientist Challenge – Entel

Esta prueba técnica tiene por objetivo evaluar tus habilidades en programación, análisis de datos y, especialmente, tu capacidad de **tomar decisiones fundamentadas en escenarios reales**.

Además del desarrollo técnico, se evaluará tu criterio analítico, claridad en la comunicación y capacidad de justificar decisiones. También se evalúa el uso de Git como sistema de control de versiones y el orden en el código para garantizar su reproducibilidad. Se recomienda guardar el desarrollo en tu plataforma de almacenamiento de repositorios favorita (GitHub, Bitbucket, GitLab, etc.) en un repositorio privado y dar acceso al correo desde el cual se te envió la prueba

Instrucciones generales

1. Debes responder el mail con asunto:
“Challenge Data Scientist - [Nombre][Apellido]”
2. Debes adjuntar el link a tu repositorio.
3. Se aceptarán cambios en el repositorio hasta la fecha definida en el mail.
4. El repositorio debe contener:
 - Código reproducible (Python, R u otro)
 - Instrucciones claras para ejecutar la solución
 - Todos los archivos necesarios

Contexto del problema

Se te entrega un archivo llamado `dataset_prueba.csv`, con información de 299.997 clientes de una TELCO durante un período de 3 meses.

Incluye variables como:

- Uso de red (2G, 3G)
- Recargas
- Llamadas emitidas y recibidas
- ARPU (average revenue per user)

Además contiene otras columnas relevantes como:

- `mobile_number` (identificador)
- `last_date_of_month` (fecha)

- churn (variable objetivo)

El objetivo es **analizar y predecir el churn de clientes**, entendiendo que la fuga de clientes es un problema crítico para el negocio.

Primera parte: Análisis exploratorio (EDA)

Debes separar el dataset en:

- **Entrenamiento:** fecha 06/30/2014 y 07/31/2014
- **Test:** fecha 08/31/2014

Utiliza estos conjuntos de la forma que consideres más adecuada a lo largo del análisis y modelamiento. Si corresponde, explica y justifica tus decisiones.

1. Segmentación de clientes por revenue

Crea una segmentación de clientes basada en la columna *ARPU*.

- Define tu propio criterio de segmentación
- Explica por qué elegiste ese criterio
- Describe cómo se distribuyen los clientes en cada segmento

2. Generación de variables

A partir de la información disponible:

- Crea al menos una nueva variable (feature) que consideres relevante para el problema
- Describe cómo la construiste
- Justifica por qué crees que aporta valor para predecir churn

3. Análisis de churn

Analiza cómo se comporta el churn en los meses disponibles.

- Describe patrones relevantes
- Identifica variables que podrían estar relacionadas con churn
- Puedes apoyarte en visualizaciones si lo consideras necesario
- Compara clientes que hacen churn vs los que no

4. Limpieza de datos (decisión abierta)

Define tu estrategia de limpieza de datos.

- ¿Qué columnas eliminarías y por qué?

- ¿Cómo tratarías valores nulos?
- ¿Hay algo en los datos que te genere desconfianza?
- ¿Qué riesgos tiene tu enfoque?

5. Otros análisis (opcional)

- Si consideras que existe algún análisis adicional relevante para entender el churn o mejorar la solución, puedes incluirlo en esta sección.
- No existe una dirección específica: se valorará tu criterio para identificar oportunidades de análisis más allá de lo solicitado.

Segunda parte: Modelo predictivo

Restricción de negocio (IMPORTANTE)

La empresa solo puede contactar a **2000 de los clientes cada mes** debido a limitaciones operativas.

Cada contacto tiene un costo de **\$1000 CLP por cliente**.

Adicionalmente, se asume que:

- El valor total recuperado por un cliente retenido es de **\$30.000 CLP**
- La tasa de éxito de retención de la campaña es de solo el **10%** sobre los que efectivamente habrían hecho churn.

Para esta sección, utiliza estos supuestos de negocio para tu análisis y toma de decisiones.

6. Modelamiento

Desarrolla uno o más modelos que permitan predecir churn. Justifica por qué elegiste ese enfoque frente a otras alternativas.

¿Cómo evaluarías tu modelo considerando las métricas de negocio?

7. Priorización de clientes

Dado que solo puedes actuar sobre 2000 clientes:

- Define cómo seleccionarías esos clientes
- Explica tu estrategia (ranking, scoring, etc.)
- Justifica por qué es adecuada para el negocio

8. Mejora del modelo

- ¿Qué harías para mejorar la performance?
- ¿Qué información adicional te gustaría tener?
- ¿Si tuvieras que implementar esta solución en producción en el corto plazo, qué simplificarías?

Resumen de decisiones (obligatorio)

(Máximo 1 página)

Incluye un archivo (por ejemplo: decisiones.md o decisiones.pdf) donde resumas:

- Las decisiones más relevantes que tomaste
- Supuestos clave
- Principales riesgos de tu solución

Este resumen debe ser claro y conciso, y permitir entender rápidamente tu enfoque.

Análisis detallado

Puedes incluir análisis adicionales, gráficos o justificaciones más extensas dentro del repositorio (notebooks, el mismo script u otros documentos). Si necesitas realizar supuestos adicionales, puedes definirlos explícitamente. **Se valorará la relevancia del análisis por sobre la cantidad.**

Etapas posteriores

Los candidatos que pasen esta prueba participarán en una **entrevista técnica**, donde **deberán explicar y defender su solución.**

Se espera que puedas profundizar en:

- Las decisiones tomadas
- Supuestos y trade-offs
- Limitaciones de tu enfoque